DIT DAKAR INSTITUTE OF TECHNOLOGY

L'école de l'Intelligence Artificielle

Introduction au Machine learning

Abdoul Wahab Diallo

DIT

19 octobre 2026

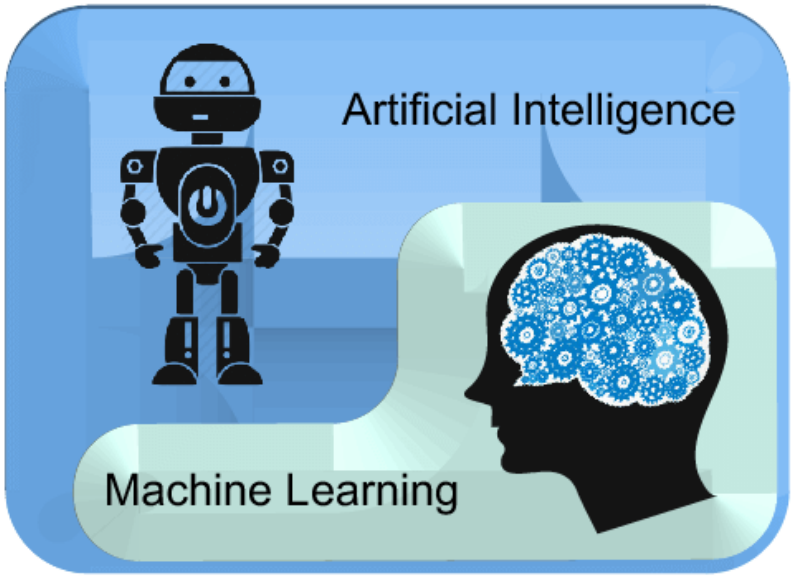
1 **Définition du Machine Learning**

2 **Types d'algorithmes en Machine learning**

3 **Apprentissage Supervisé**
- Introduction à la classification
- Logistic Regression
- Decision Tree
- Ensemble learning
- Méthodes de splitting (fractionnement)
- Métriques d'évaluation

Qu'est-ce que le machine learning ?

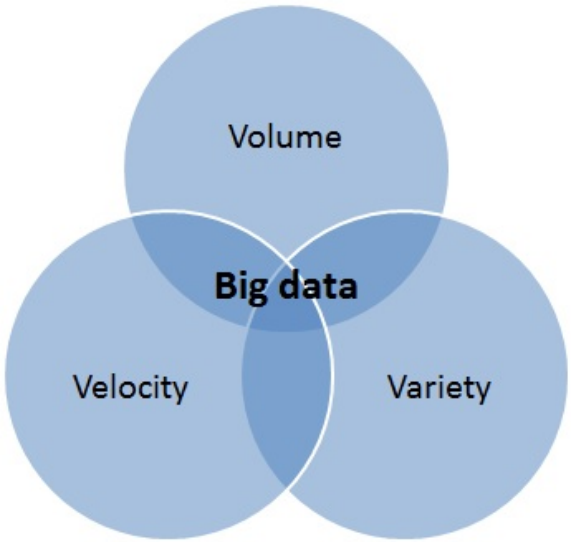
L'intelligence artificielle est l'ensemble des théories et des techniques mises en œuvre en vue de réaliser des machines capables de simuler l'intelligence humaine



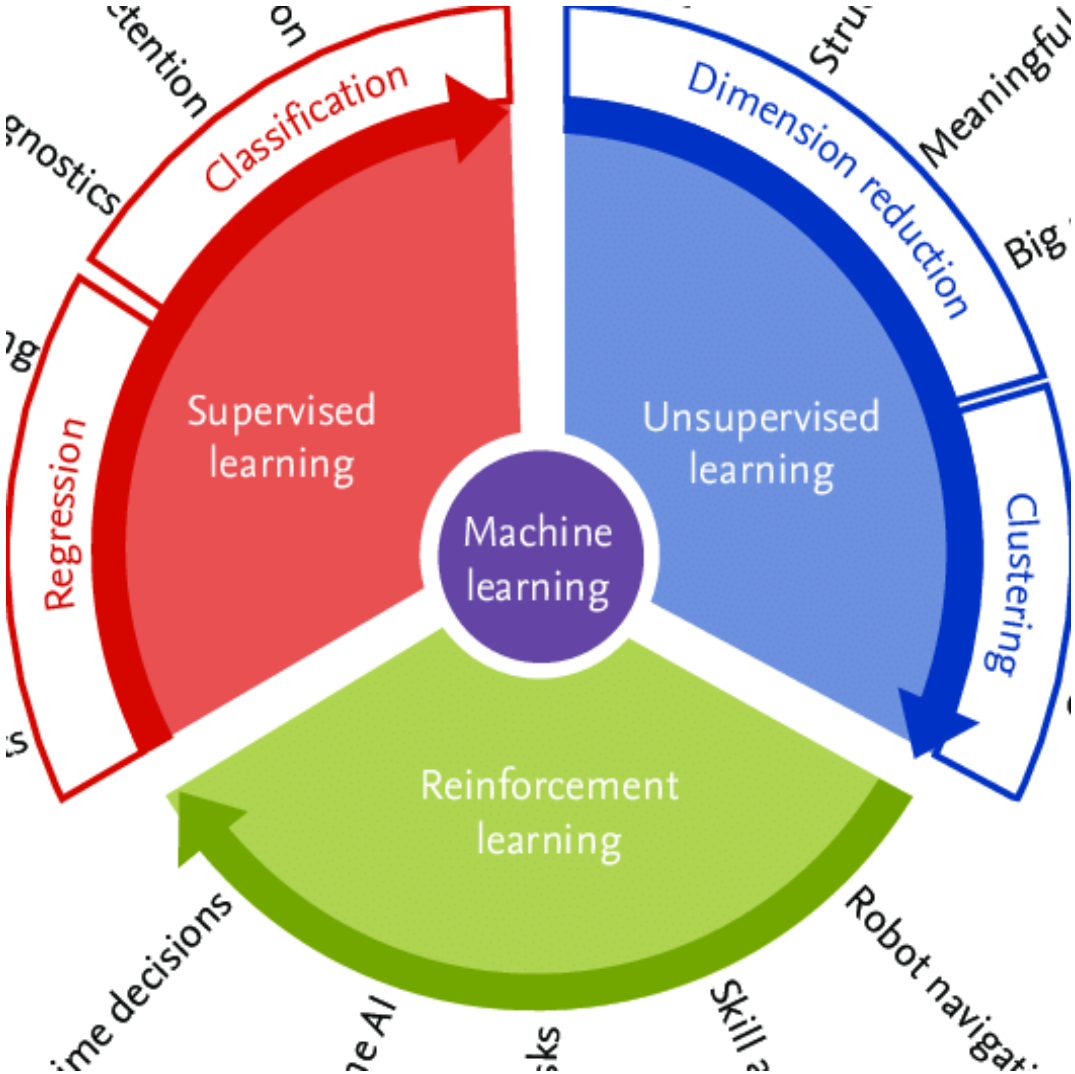
Le machine learning (ML) est une technologie d'intelligence artificielle (IA) qui est axée sur la création de systèmes qui apprennent, ou améliorent leurs performances, en fonction des données qu'ils traitent afin de pouvoir faire une tâche bien définie.

Les Big Data sont des données trop volumineuses et complexes pour que les outils de données conventionnels puissent les capturer, les stocker, les gérer et les analyser.

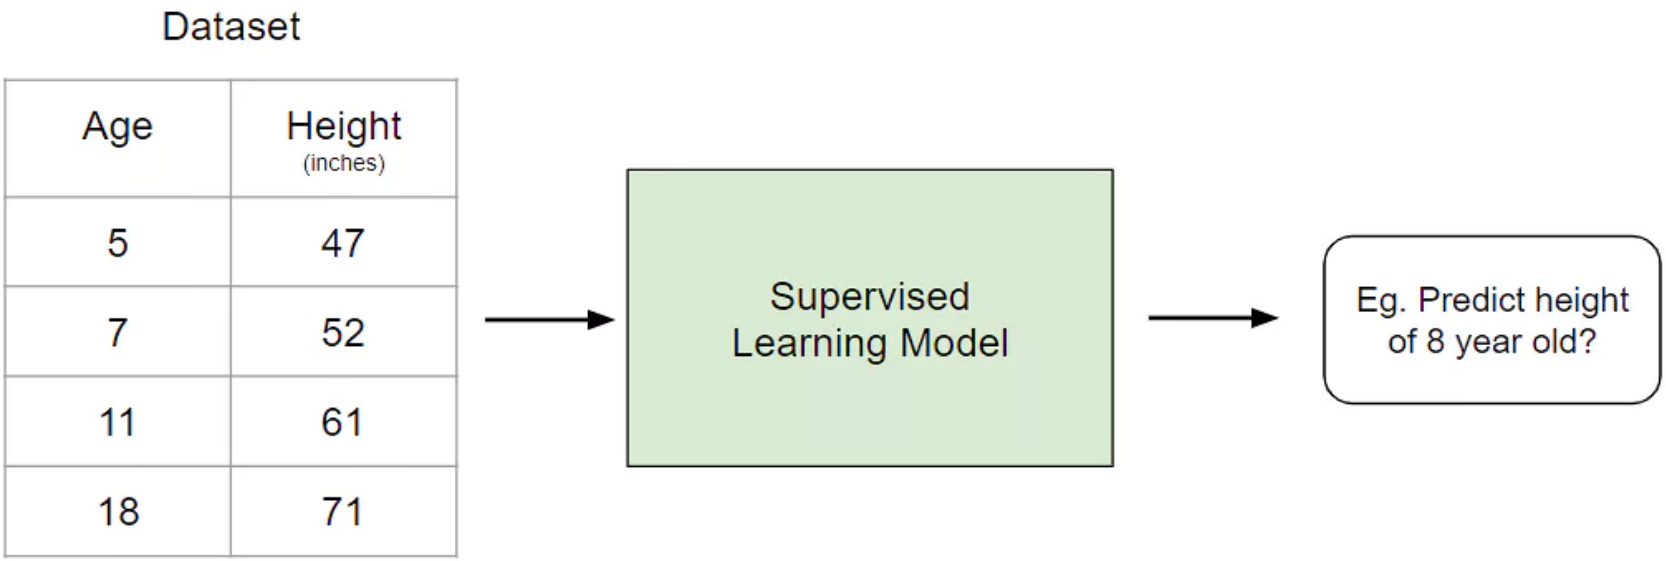
- Les Big data sont généralement caractérisées par ce que l'on appelle communément les 3 Vs



- Les Big Data sont l'essence du Machine Learning.


Classification
Dimension reduction
Regression
Supervised learning
Unsupervised learning
Clustering
Machine learning
Reinforcement learning
Meaningfu
Big
Robot navigati

Dans l'apprentissage supervisé, les données sont étiquetées(labelisées), ce qui signifie que pour un ensemble de données d'entrées, nous avons la variable de sortie et un modèle est formé sur la base des données existantes pour prédire la sortie pour un nouvel ensemble d'entrées.

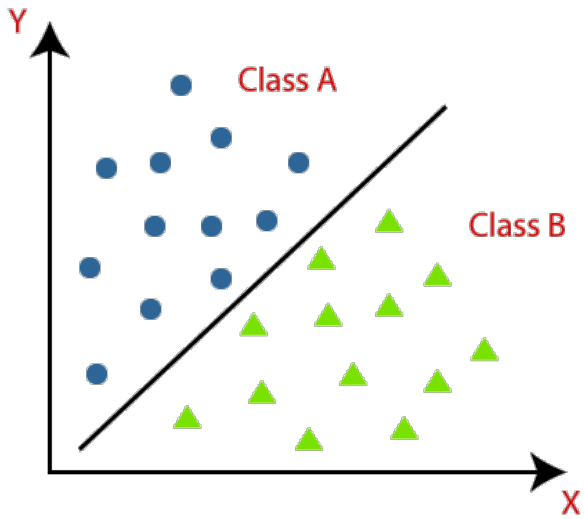


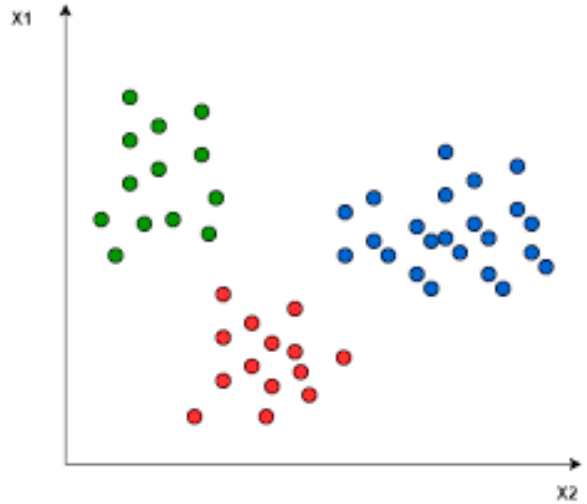
Nous avons deux types d'apprentissage supervisées

- Apprentissage par Régression
- Classification supervisée

La classification fait généralement référence à tout type de problème où un type spécifique d'étiquette (label) de classe est le résultat à prédire à partir d'un ensemble de données d'entrée donné.

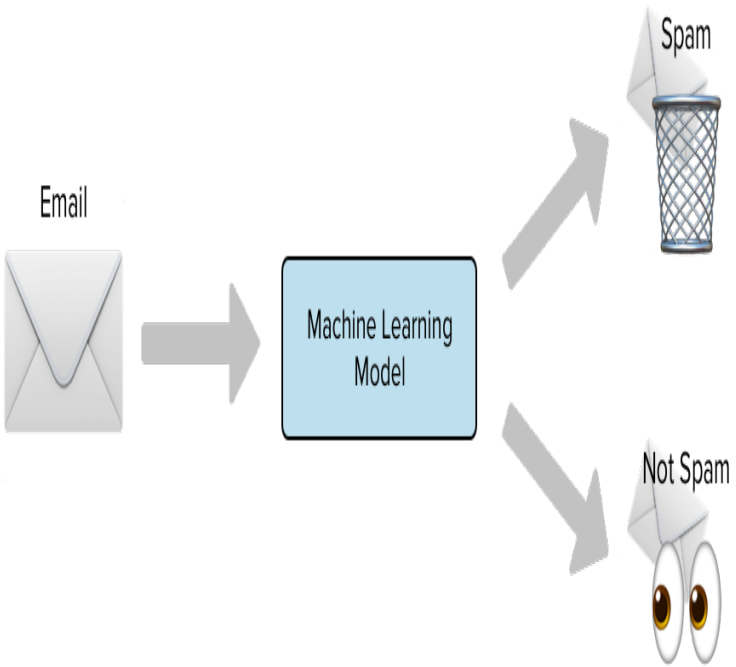
- La classification est parfois séparée en **classification binaire**, qui est le cas particulier de la distinction entre exactement deux classes
- **classification multi-classes**, qui est la classification entre plus de deux classes.



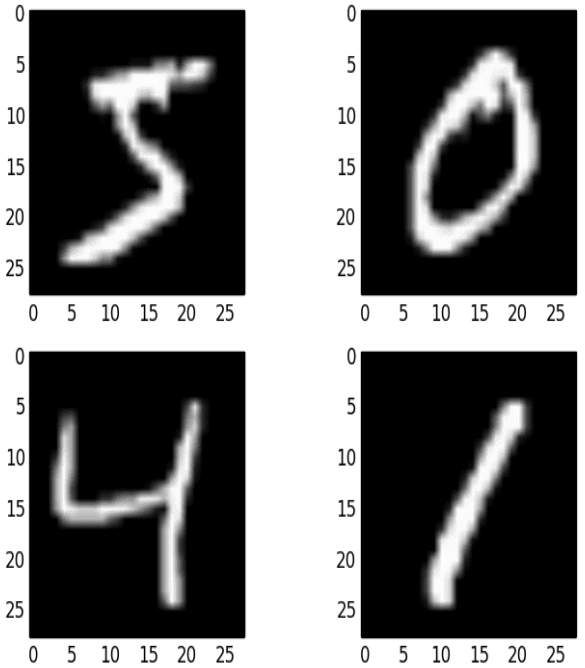


Applications de la classification

- Détection du spam dans les e-mails (spam ou non)



- Détection de chiffre Manuscrits

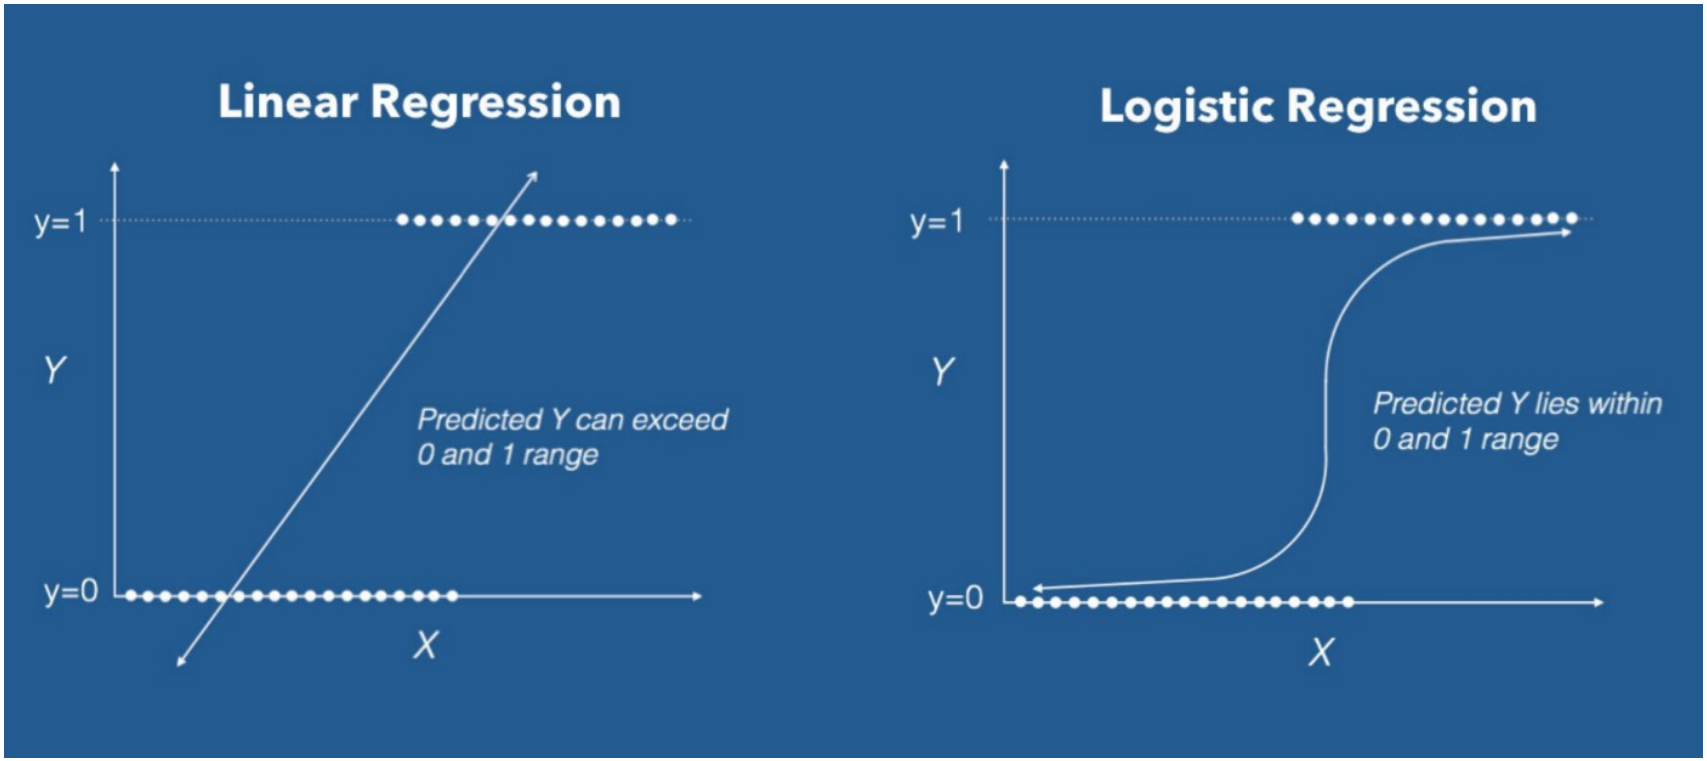


Exemples d'algorithmes de classification

Aujourd'hui nous avons plusieurs types d'algorithmes de classification implémentés et faciles d'accès parmi eux :

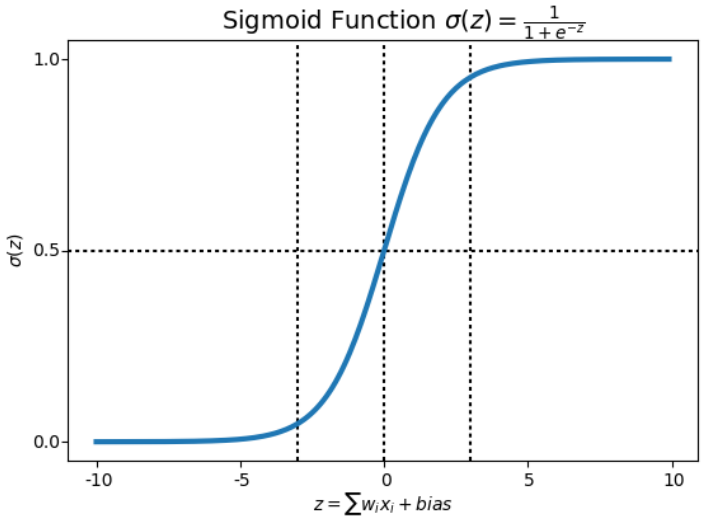
- K-Nearest Neighbours
- Logistic Regression
- Support vector machine
- Naive Bayes classifier
- Decision Trees
- Random forest
- Neurones Networks

La régression logistique est un algorithme d'apprentissage automatique qui est utilisé pour les problèmes de classification, c'est un algorithme basé sur le concept de probabilité.



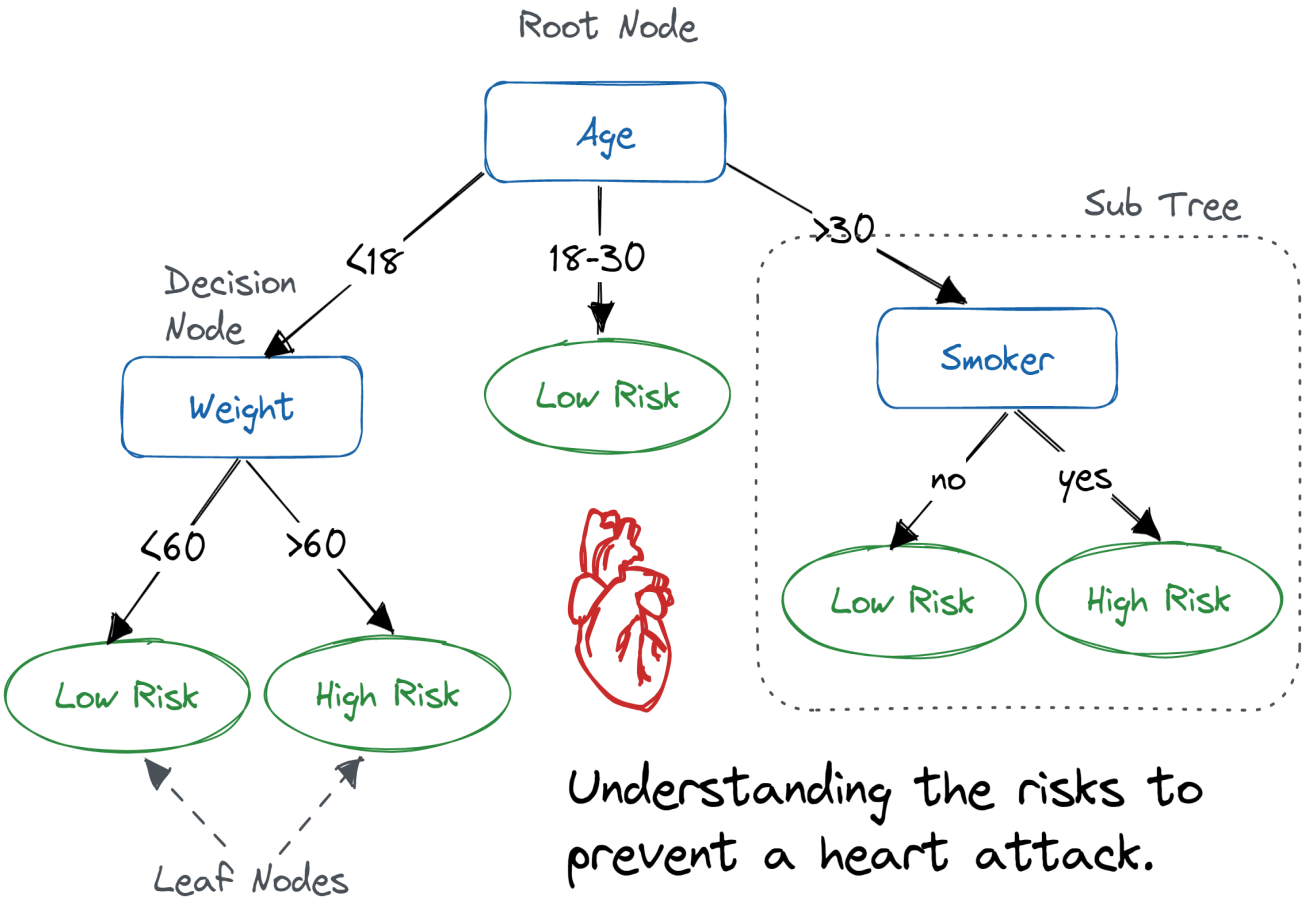
Fonction Sigmoïde

- La fonction Sigmoïde retourne une valeur réelle valeur comprise entre 0 et 1.



- **fonction de Régression logistique**
- $\sigma(z) = \frac{1}{1+\exp(-z)}$

Decision Tree est un algorithme de machine learning utilisé plus en Classification.



Choix de la caractéristique du noeud racine

Pour sélectionner la caractéristique à partir de laquelle on fera le splitting (division) de notre arbre, on utilise les mesures : l'Entropie ou le gini index

Entropie & Gini index : Ils mesurent l'impureté d'un nœud. Par impureté, nous entendons la mesure de l'hétérogénéité d'un nœud particulier.

Exemple : Supposons que nous avons 50 femmes et 50 hommes dans un ensemble de données. Dans ce cas, les deux proportions sont égales. Par conséquent, l'entropie ou le gini index serait de 1, ce qui signifie que l'ensemble est hétérogène. Mais si l'ensemble contient 98 hommes et 2 femmes au lieu de la proportion 50-50, alors l'entropie ou le gini index sera faible (plus proche de 0).

Gini Index

$$I_G = 1 - \sum_{j=1}^{c} p_j^2$$

Entropy

$$I_H = -\sum_{j=1}^{c} p_j log_2(p_j)$$

Information Gain (gain d'information)

L'information gain mesure la diminution de l'entropie (de l'impureté) obtenue en divisant un nœud S selon une variable A.

- Entropie d'un nœud S à K classes (p_k : proportion de la classe k dans S) :

$$H(S) = -\sum_{k=1}^{K} p_k \log_2 p_k$$

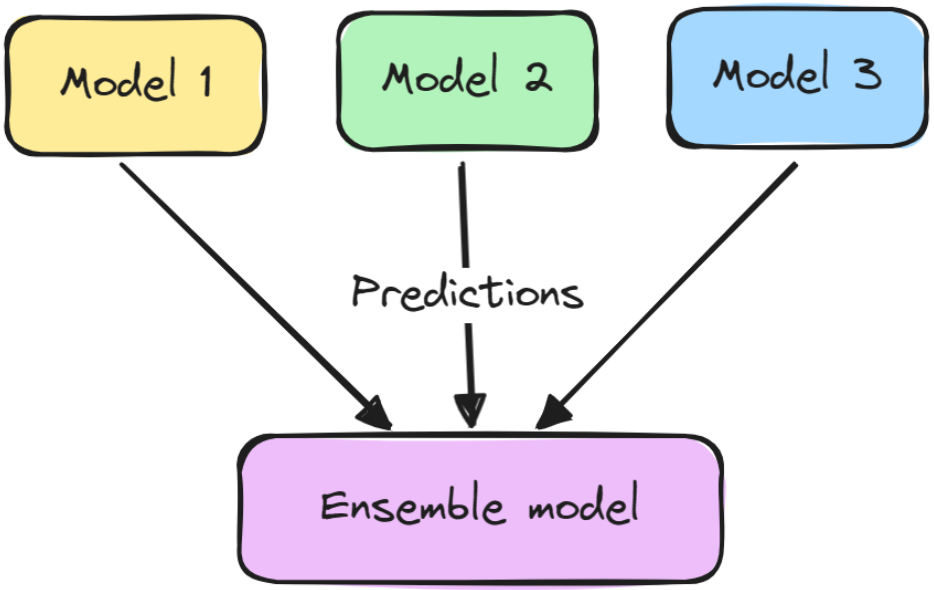
- Information gain de la variable A (S_v : individus de S tels que $A = v$) :

$$IG(S, A) = H(S) - \sum_{v \in \text{Valeurs}(A)} \frac{|S_v|}{|S|} H(S_v)$$

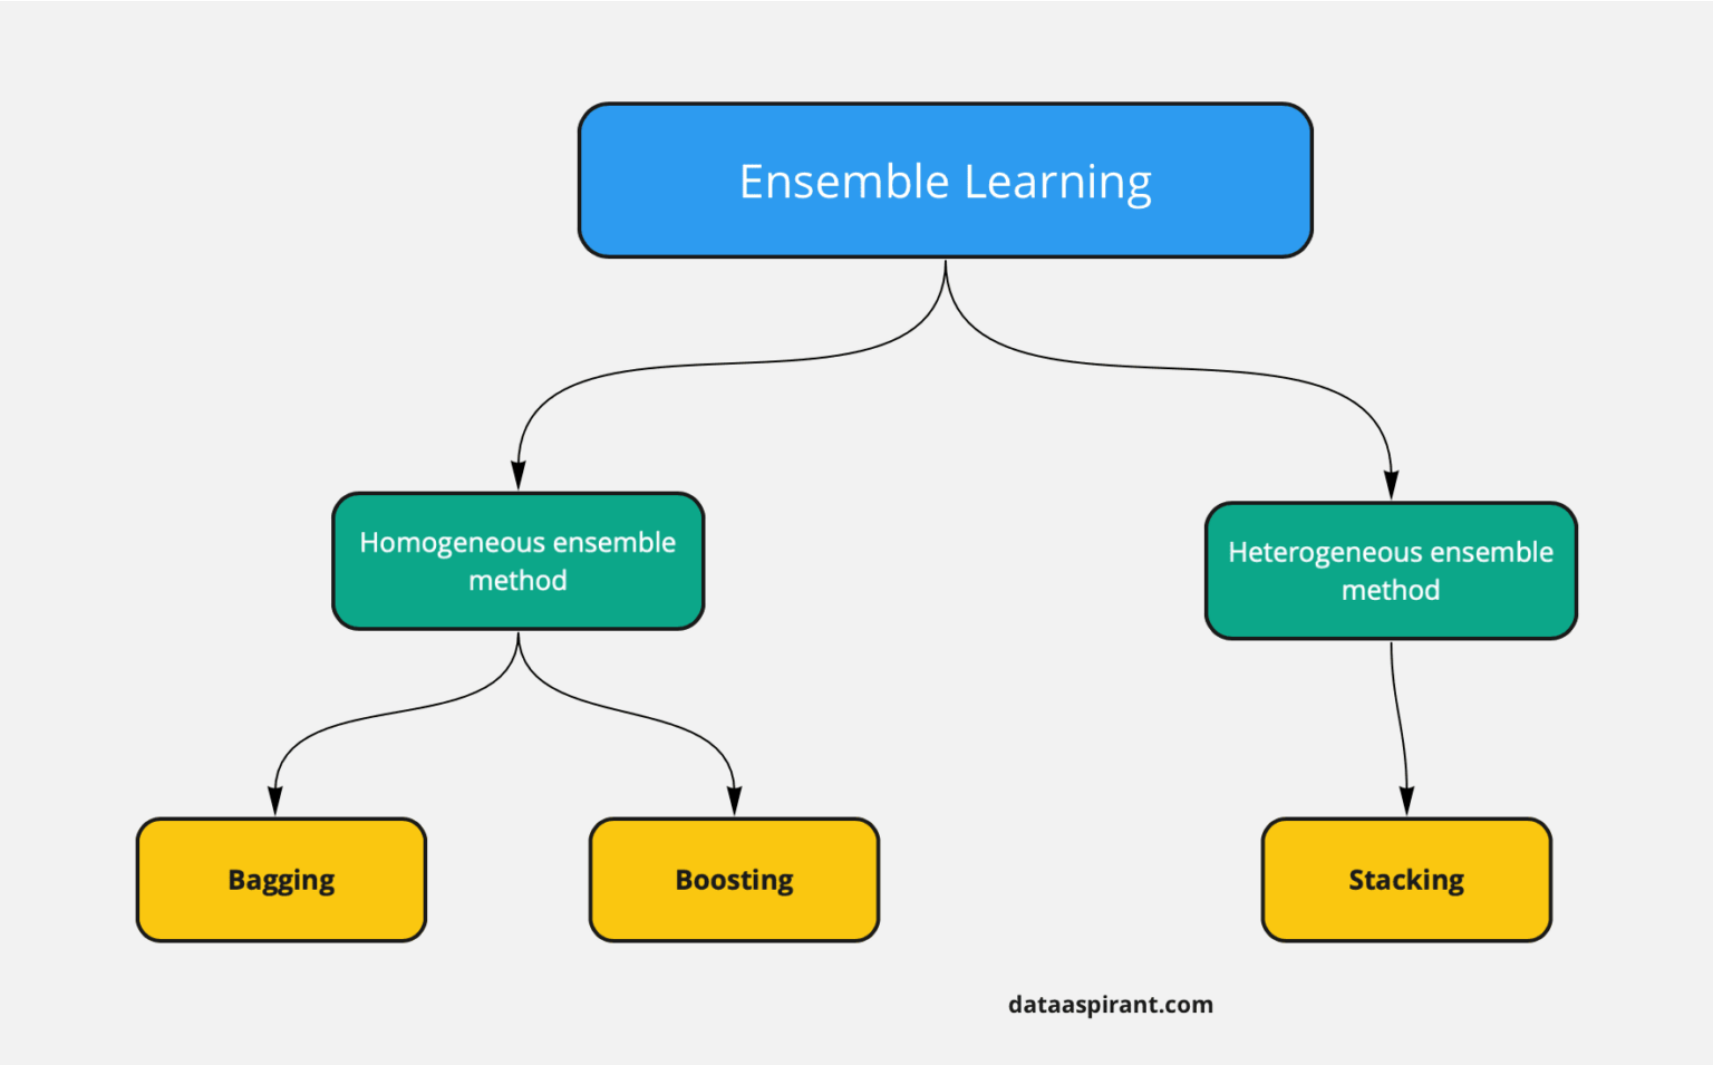
Choix de la variable de split

On calcule $IG(S, A)$ pour chaque variable candidate et on divise le nœud selon la variable qui a l'information gain le plus élevé. On répète ensuite la procédure sur chaque nœud enfant.

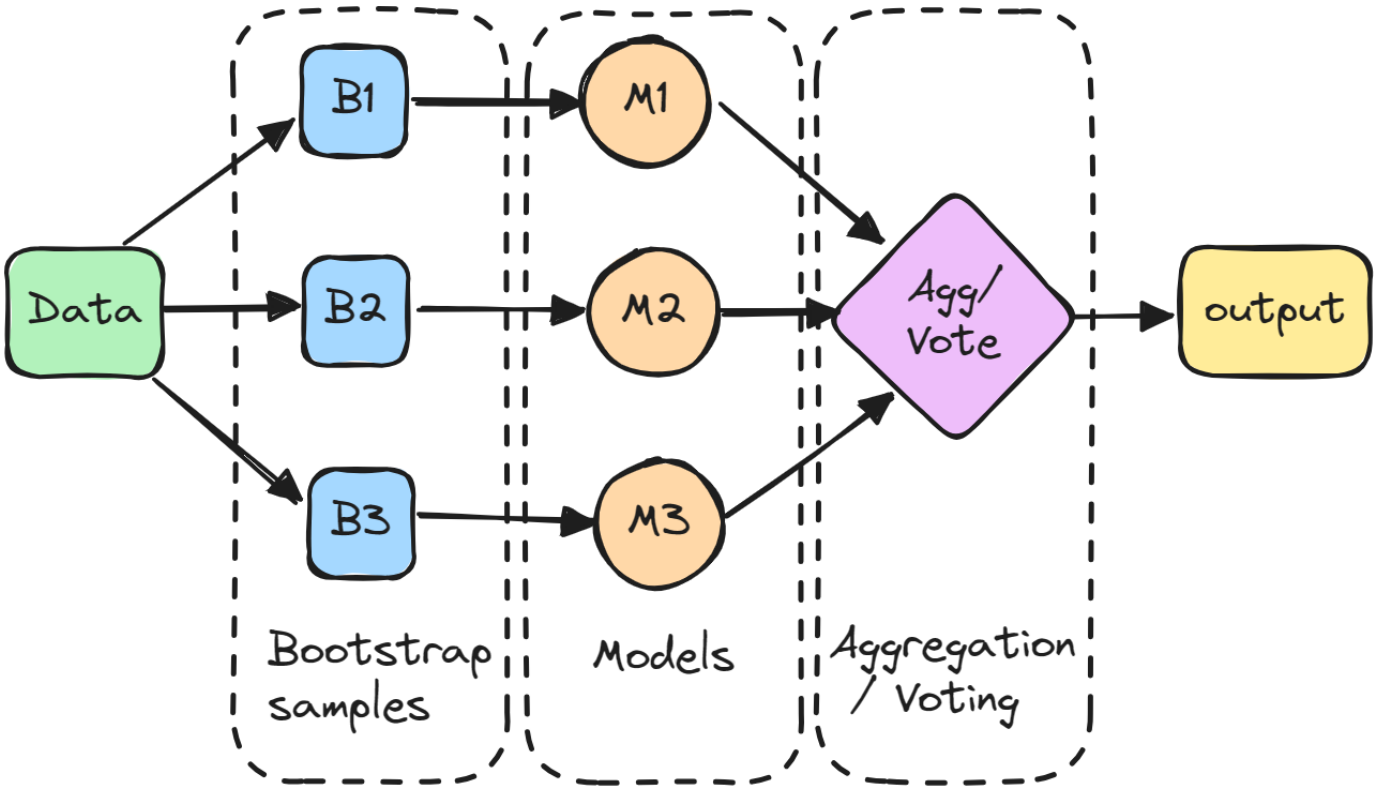
L'ensemble learning est une approche générale de machine learning qui vise à améliorer les performances prédictives en combinant les prédictions de plusieurs modèles. L'ensemble learning est utilisé pour classification comme pour la régression.



Les trois principales catégories de méthodes d'ensemble learning sont : **Bagging**,**Boosting** et **Stacking**

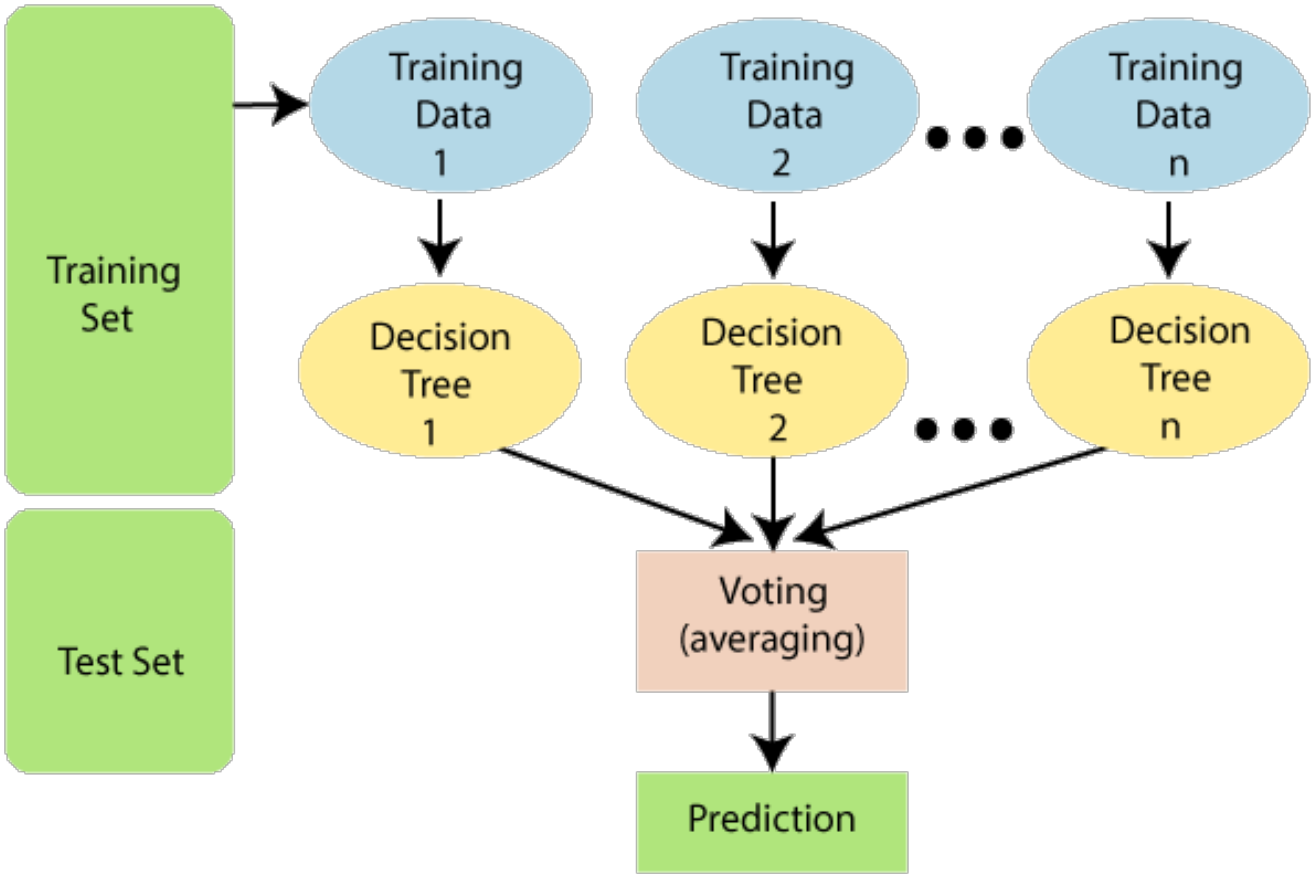

Ensemble Learning
Homogeneous ensemble method
Heterogeneous ensemble method
Bagging
Boosting
Stacking
dataaspirant.com

Bagging (bootstrap aggregating) est une méthode ensembliste qui consiste à entrainer plusieurs modèles indépendamment sur des sous-ensembles aléatoires de données et à agréger leurs prédictions par le biais d'un vote ou d'un calcul de moyenne.



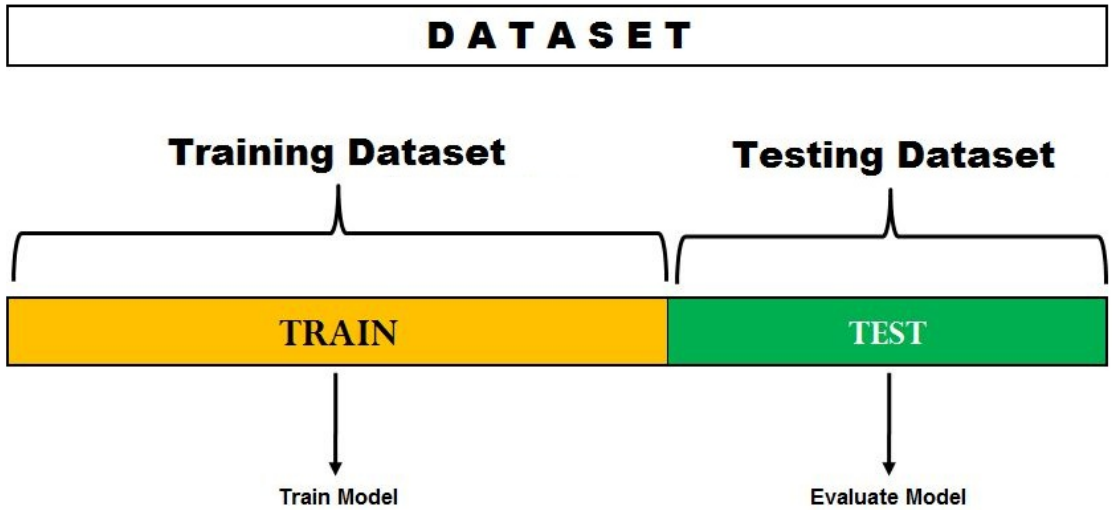
Bagging ensemble learning : Random Forest

Random Forest est une méthode de Bagging qui fonctionne en construisant une multitude d'arbres de décision (decision tree) au moment de l'entrainement. Il est utilise pour la classification et la régression.



Méthode de Hold Out

Il s'agit de la méthode d'évaluation la plus simple et elle est largement utilisée dans les projets d'apprentissage automatique. Ici, l'ensemble des données (population) est divisé en deux ensembles : l'ensemble d'entraînement et l'ensemble de test. Les données peuvent être divisées en 70-30 ou 60-40, 75-25 ou 80-20, ou même 50-50 selon le cas d'utilisation. En règle générale, la proportion de données d'entraînement doit être supérieure à celle des données de test.



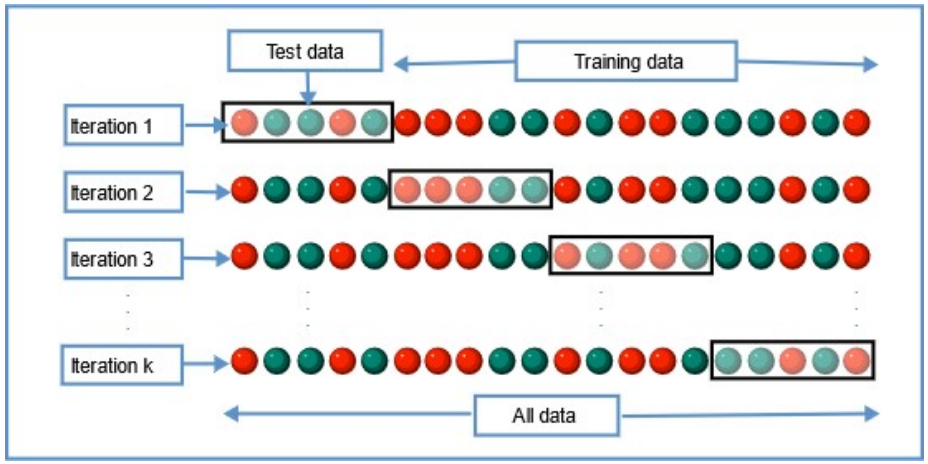
Exemple de splitting

x		y
1	2	0
3	4	1
5	6	1
7	8	0
9	10	1
11	12	0
13	14	0
15	16	1
17	18	1
19	20	0
21	22	1
23	24	0

x		y	
17	18	1	Training set
5	6	1	
23	24	0	
1	2	0	
3	4	1	
11	12	0	
15	16	1	
21	22	1	
7	8	0	Test set
9	10	1	
13	14	0	
19	20	0	

K-Fold Cross-Validation

Dans cette technique de rééchantillonnage, l'ensemble des données est divisé en k ensembles de tailles presque égales. Le premier ensemble est sélectionné comme ensemble de test et le modèle est entraîné sur les k-1 ensembles restants. Dans la deuxième itération, le deuxième ensemble est sélectionné comme ensemble de test et les k-1 ensembles restants sont utilisés pour l'entraînement. Ce processus se poursuit pour tous les k ensembles.



Matrice de confusion

Confusion Matrix		Predicted	
		Negative	Positive
Actual	Negative	True Negative (TN)	False Positive (FP)
	Positive	False Negative (FN)	True Positive (TP)

- Accuracy : Il s'agit du pourcentage du nombre total de prédictions correctes par rapport au nombre total de prédictions.

$$\textbf{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

- Précision : Il s'agit du pourcentage d'événements positifs prédits qui sont effectivement positifs.

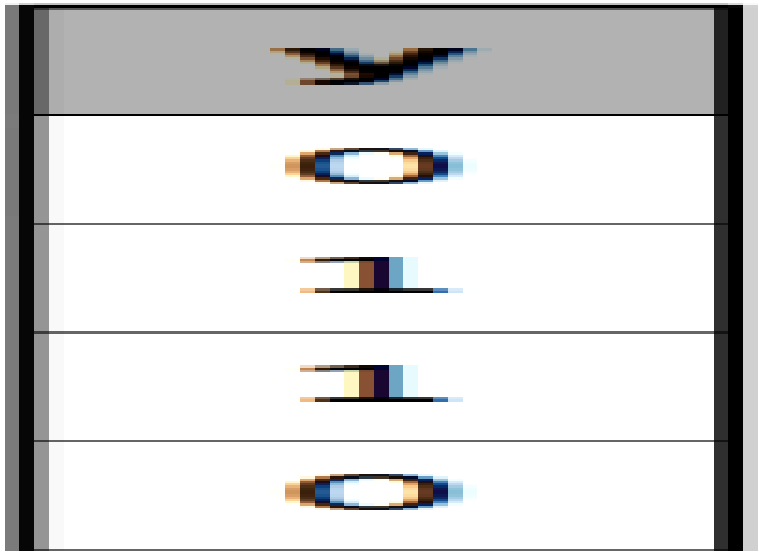
$$\textbf{Précision} = TP / (TP + FP)$$

- Rappel (Recall) : Il s'agit du pourcentage d'événements positifs que sont correctement prédits.

$$\textbf{Rappel} = TP / (TP + FN)$$

Exemple de matrice de confusion

7	8	0	Test set
9	10	1	
13	14	0	
19	20	0	



Matrice de confusion

	Label : 1	**Label : 0**
Label : 1	1	1
Label : 0	0	2

$$\textbf{Accuracy} = \frac{3}{4} = 0.75$$

- Le F1 Score est la moyenne harmonique des valeurs de précision et de rappel pour un problème de classification. La formule du F1 Score est la suivante :

$$F_1 = \left(\frac{\mathrm{recall}^{-1} + \mathrm{precision}^{-1}}{2} \right)^{-1} = 2 \cdot \frac{\mathrm{precision} \cdot \mathrm{recall}}{\mathrm{precision} + \mathrm{recall}}.$$